Big Data Fundamentals

Prak 02 – Zaeni Ahmad (24.01.5122)`

Tugas 01 – Dataset wine quality (UCL ML Repository)

1. Sumber dataset
   - Repository: UCI Machine Learning Repository
   - URL: https://archive.ics.uci.edu/ml/machine-learning-databases/wine-quality/winequality-red.csv
   - Judul: Wine Quality – Red Wine
   - Delimiter: Semicolon (;)
   - Kontributor: P. Cortez et al. (2009)

2. Kode implementasi

   Lima baris pertama dari dataset wine quality:

```
# ── 5 Baris Pertama ──────────────────────────────────────────
print('=== df.head() ===')
df_wine.head()
```

```
=== df.head() ===
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
0	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51	0.56	9.4	5
1	7.8	0.88	0.00	2.6	0.098	25.0	67.0	0.9968	3.20	0.68	9.8	5
2	7.8	0.76	0.04	2.3	0.092	15.0	54.0	0.9970	3.26	0.65	9.8	5
3	11.2	0.28	0.56	1.9	0.075	17.0	60.0	0.9980	3.16	0.58	9.8	6
4	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51	0.56	9.4	5

   Hasil df.info()

```python
# — Informasi Dataset ————————————————————————————————————————
print('=== df.info() ===')
df_wine.info()
```

```
=== df.info() ===
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1599 entries, 0 to 1598
Data columns (total 12 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   fixed acidity         1599 non-null   float64
 1   volatile acidity      1599 non-null   float64
 2   citric acid           1599 non-null   float64
 3   residual sugar        1599 non-null   float64
 4   chlorides             1599 non-null   float64
 5   free sulfur dioxide   1599 non-null   float64
 6   total sulfur dioxide  1599 non-null   float64
 7   density               1599 non-null   float64
 8   pH                    1599 non-null   float64
 9   sulphates             1599 non-null   float64
 10  alcohol               1599 non-null   float64
 11  quality               1599 non-null   int64
dtypes: float64(11), int64(1)
memory usage: 150.0 KB
```

Dataset memiliki 1.599 baris dan 12 kolom. Semua kolom bertipe numerik (float64/int64). Tidak ditemukan missing values pada seluruh kolom. dataset sangat bersih dan siap dianalisis.

Hasil dari df.describe()

```python
# — Statistik Deskriptif ————————————————————————————————————
print('=== df.describe() ===')
df_wine.describe().round(3)
```

=== df.describe() ===

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
count	1599.000	1599.000	1599.000	1599.000	1599.000	1599.000	1599.000	1599.000	1599.000	1599.000	1599.000	1599.000
mean	8.320	0.528	0.271	2.539	0.087	15.875	46.468	0.997	3.311	0.658	10.423	5.636
std	1.741	0.179	0.195	1.410	0.047	10.460	32.895	0.002	0.154	0.170	1.066	0.808
min	4.600	0.120	0.000	0.900	0.012	1.000	6.000	0.990	2.740	0.330	8.400	3.000
25%	7.100	0.390	0.090	1.900	0.070	7.000	22.000	0.996	3.210	0.550	9.500	5.000
50%	7.900	0.520	0.260	2.200	0.079	14.000	38.000	0.997	3.310	0.620	10.200	6.000
75%	9.200	0.640	0.420	2.600	0.090	21.000	62.000	0.998	3.400	0.730	11.100	6.000
max	15.900	1.580	1.000	15.500	0.611	72.000	289.000	1.004	4.010	2.000	14.900	8.000

Nilai quality berkisar antara 3 hingga 8 dengan distribusi:

- Quality 3: 10 sampel (0,6%) — kualitas sangat rendah
- Quality 4: 53 sampel (3,3%)
- Quality 5: 681 sampel (42,6%) — paling banyak
- Quality 6: 638 sampel (39,9%)
- Quality 7: 199 sampel (12,4%)
- Quality 8: 18 sampel (1,1%) — kualitas sangat tinggi

Visualisasi

```python
# ── Visualisasi ──────────────────────────────────────────────────────────
fig, axes = plt.subplots(1, 3, figsize=(16, 5))
fig.suptitle('Eksplorasi Data: Wine Quality (Red Wine)', fontsize=14, fontweight='bold')

# Plot 1: Distribusi Quality
quality_counts = df_wine['quality'].value_counts().sort_index()
colors = ['#d73027','#fc8d59','#fee090','#91bfdb','#4575b4','#313695']
axes[0].bar(quality_counts.index, quality_counts.values, color=colors, edgecolor='white')
for k, v in quality_counts.items():
    axes[0].text(k, v + 5, str(v), ha='center', fontsize=9, fontweight='bold')
axes[0].set_title('Distribusi Kualitas Wine')
axes[0].set_xlabel('Quality Score')
axes[0].set_ylabel('Jumlah')

# Plot 2: Alcohol vs Quality (Boxplot)
df_wine.boxplot(column='alcohol', by='quality', ax=axes[1],
                boxprops=dict(color='#2E86AB'),
                medianprops=dict(color='#F18F01', linewidth=2))
axes[1].set_title('Alcohol vs Quality')
axes[1].set_xlabel('Quality Score')
axes[1].set_ylabel('Alcohol (%)')
plt.sca(axes[1]); plt.title('Alcohol vs Quality')

# Plot 3: Heatmap Korelasi
key_cols = ['alcohol', 'volatile acidity', 'citric acid', 'sulphates', 'pH', 'quality']
corr = df_wine[key_cols].corr()
sns.heatmap(corr, annot=True, fmt='.2f', cmap='RdYlBu', ax=axes[2],
            linewidths=0.5, annot_kws={'size': 8})
axes[2].set_title('Heatmap Korelasi')
axes[2].tick_params(axis='x', rotation=45, labelsize=8)
axes[2].tick_params(axis='y', rotation=0, labelsize=8)

plt.tight_layout()
plt.savefig('wine_analysis.png', dpi=150, bbox_inches='tight')
plt.show()
```

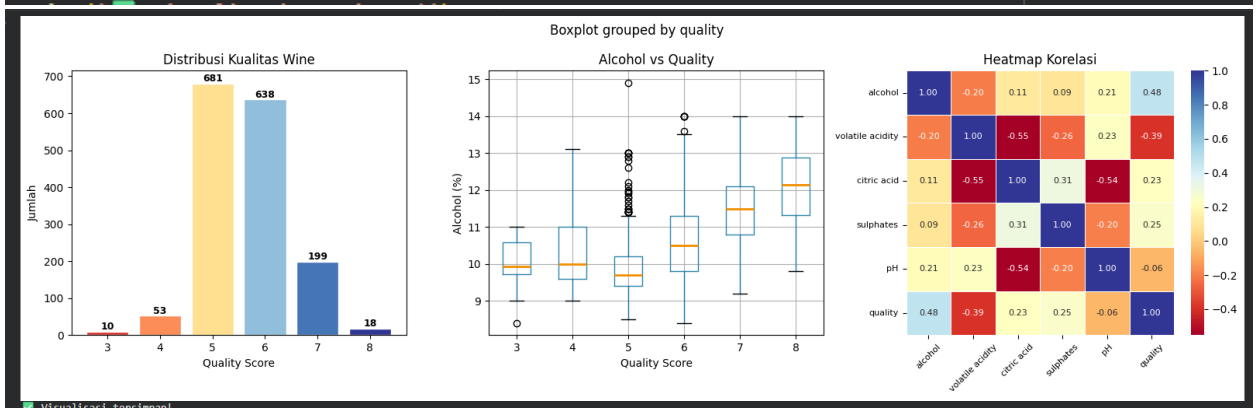

Dari visualisasi terlihat bahwa kadar alkohol berkorelasi positif dengan kualitas wine, sementara volatile acidity berkorelasi negatif. Wine berkualitas 5-6 mendominasi dataset ini.

Tugas 02 – Dataset titanic dari Kaggle

1. Sumber dataset
   - Platform: Kaggle
   - Kompetisi: Titanic – Machine Learning from Disaster
   - URL: https://www.kaggle.com/competitions/titanic
   - File yang digunakan: train.csv (891 baris, 12 kolom)

2. Kode implementasi

Hail df.head()

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

Hasil df.describe()

	PassengerId	Survived	Pclass	Age	SibSp	Parch	Fare
count	891.00	891.00	891.00	714.00	891.00	891.00	891.00
mean	446.00	0.38	2.31	29.70	0.52	0.38	32.20
std	257.35	0.49	0.84	14.53	1.10	0.81	49.69
min	1.00	0.00	1.00	0.42	0.00	0.00	0.00
25%	223.50	0.00	2.00	20.12	0.00	0.00	7.91
50%	446.00	0.00	3.00	28.00	0.00	0.00	14.45
75%	668.50	1.00	3.00	38.00	1.00	0.00	31.00
max	891.00	1.00	3.00	80.00	8.00	6.00	512.33

- Shape: 891 baris × 12 kolom
- Tipe data: int64 (PassengerId, Survived, Pclass, SibSp, Parch), float64 (Age, Fare), object (Name, Sex, Ticket, Cabin, Embarked)
- Missing values: Age (177 baris / 19,9%), Cabin (891 / 100%), Embarked (1 baris)
- Distribusi Survived: 0 (tidak selamat) = 549 (61,6%) | 1 (selamat) = 342 (38,4%)

Visualisasi

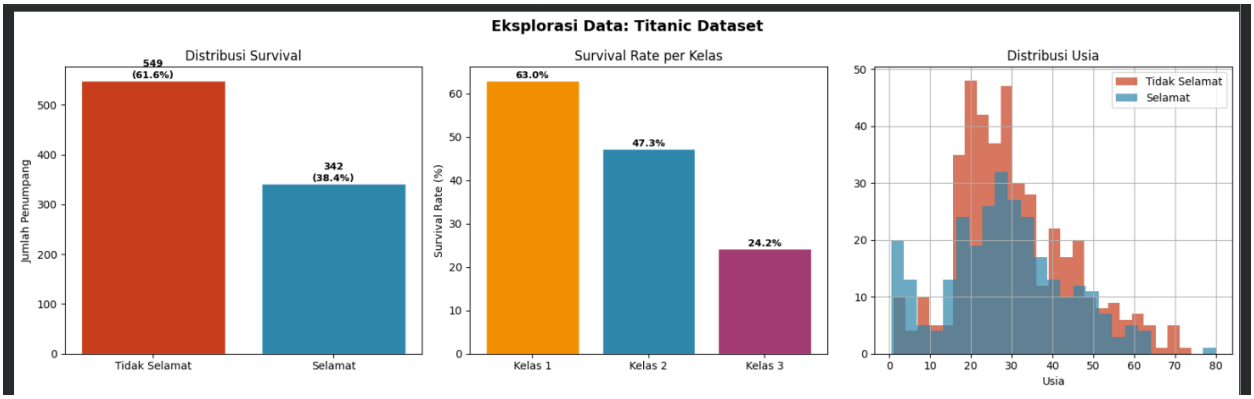

Dari visualisasi: penumpang kelas 1 memiliki survival rate tertinggi (~60%), menunjukkan korelasi antara kelas tiket dan keselamatan. Distribusi usia antara survivor dan non-survivor cukup mirip, namun sedikit lebih banyak anak-anak di kelompok selamat.

Tugas 03 – Perbandingan dataset

Ringkasan perbandingan

UCI Machine Learning Repository dan Kaggle sama-sama menyediakan dataset publik gratis, namun keduanya memiliki karakteristik, ekosistem, dan cara akses yang berbeda. Tabel berikut merangkum perbandingan komprehensif keduanya:

Aspek	UCI ML Repository	Kaggle
Pendaftaran Akun	Tidak perlu akun. dataset langsung dapat diunduh via URL publik.	Wajib daftar dan login akun Kaggle terlebih dahulu.
Akses API	Tidak memiliki API; download dilakukan manual atau via URL langsung.	Memiliki Kaggle API resmi (kaggle.json token) yang bisa dipakai di notebook.
Cara Unduh	pd.read_csv(url) langsung dari URL atau download manual (.csv/.zip).	Install library kaggle, setup token, lalu !kaggle datasets/competitions download.
Format Data	Sebagian besar CSV atau format sederhana (semikolon/koma sebagai delimiter).	Beragam format: CSV, JSON, XLSX, ZIP, SQLite, Parquet, dan lainnya.
Jumlah Dataset	Terbatas (~600+ dataset) namun merupakan benchmark klasik di ML.	Sangat besar (100.000+ dataset) dari berbagai domain dan komunitas.

Ukuran File	Umumnya kecil hingga menengah (KB–MB).	Bervariasi, bisa sangat besar hingga beberapa GB.
Metadata / Deskripsi	Minim dokumentasi; sering butuh paper asli untuk memahami fitur.	Dokumentasi lengkap: deskripsi kolom, notebook eksplorasi, diskusi komunitas.
Kualitas Data	Sudah bersih dan terstandarisasi. cocok untuk benchmark.	Bervariasi; sebagian dataset masih raw dan memerlukan pembersihan lebih lanjut.
Lisensi	Umumnya open/research; tapi perlu cek per dataset.	Setiap dataset memiliki lisensi terpisah (CC, GPL, dll). wajib dicek.
Cocok Untuk	Penelitian akademik, pembelajaran ML klasik, benchmarking.	Kompetisi data science, proyek nyata, eksplorasi data beragam domain.

Persamaan

- Keduanya menyediakan dataset publik secara gratis untuk keperluan edukasi dan riset.
- Dataset dari keduanya dapat dimuat ke Google Colab menggunakan library Pandas (pd.read_csv()).
- Keduanya mendukung format CSV sebagai format data yang paling umum.
- Eksplorasi data dasar (head, info, describe, value_counts) berlaku sama di keduanya.

Perbedaan

- Autentikasi: UCI tidak memerlukan akun; Kaggle wajib login dan setup API token.
- Kompleksitas setup: UCI hanya 1 baris kode (pd.read_csv(url)); Kaggle membutuhkan 5-7 langkah setup.
- Volume: Kaggle jauh lebih besar (100K+ dataset vs 600+ di UCI).
- Komunitas: Kaggle memiliki notebook publik, forum, dan diskusi; UCI hanya repository statis.

Rekomendasi Penggunaan

Gunakan UCI ketika...	Gunakan Kaggle ketika...
Butuh dataset benchmark klasik (Iris, Wine, Breast Cancer)	Butuh dataset topik terkini atau spesifik industri

Ingin akses cepat tanpa setup autentikasi	Butuh inspirasi dari notebook/solusi komunitas
Untuk tugas perkuliahan dan eksperimen awal	Untuk mengikuti kompetisi atau proyek portofolio
Dataset kecil-menengah sudah cukup	Butuh dataset besar atau format non-CSV